Predicción y análisis de abandono

Chuard

Proyecto final · Minería de Datos · 13 de noviembre de 2026

Objetivo. Estimar el abandono de clientes de telecomunicaciones, comparar cinco familias de clasificación y ofrecer explicaciones y una lista de revisión para retención mediante una aplicación web.

Resultado. Se publican los datos de procedencia y calidad, tres notebooks con sus ejecuciones, diez candidatos evaluados, el pipeline congelado XGBoost sin derivadas, explicabilidad SHAP, recomendaciones determinísticas y una web Streamlit con cinco secciones. La aplicación utiliza el modelo; no lo entrena.

Evidencia	Resultado guardado
Prueba final: 1.409 registros	F1 0.622 · Recall 0.802 · ROC-AUC 0.830
Ganador versión 1.0.0	XGBoost calibrado sigmoid · umbral binario 0,25
Fuentes de revisión	README, notebooks, pruebas, manifiestos y resultados versionados

Interpretación. El recall favorece detectar abandonos, con 290 falsas alertas frente a 300 aciertos positivos. El sistema apoya revisión humana; no garantiza abandono futuro, ahorros ni efectividad causal de las sugerencias.

Repositorio: github.com/Jacklb19/Chuard

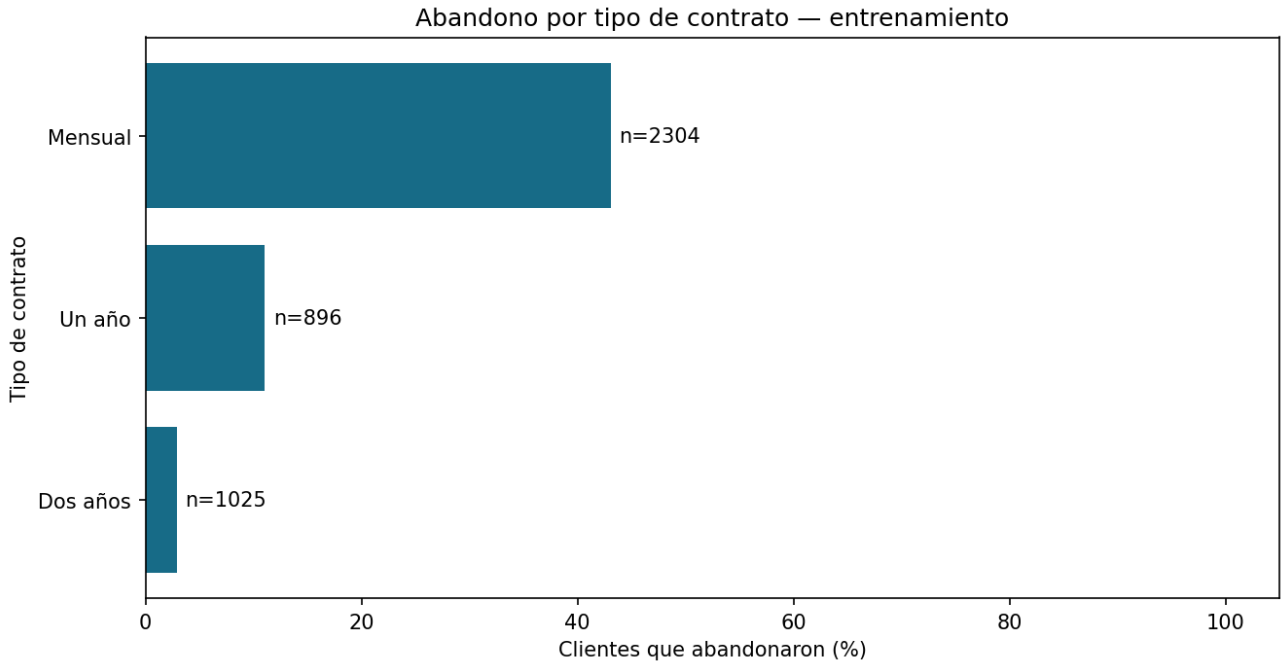
Aplicación: https://chuard.streamlit.app/

Datos, limpieza y exploración

Telco Customer Churn (Kaggle): 7.043 filas, 21 columnas, 19 predictores originales, customerID y Churn. La clase positiva es Churn=Yes: 1.869 registros (26,54%); 5.174 no abandonos. customerID y Churn nunca entran como predictores.

La revisión detectó 11 cargos acumulados vacíos, todos con antigüedad cero; se normalizan a cero. No hay filas completas ni identificadores duplicados en el original. Se conservan perfiles iguales con identificadores diferentes. Se validan categorías, números finitos no negativos y coherencia entre telefonía, internet y servicios asociados.

El EDA estadístico se limita a entrenamiento (4.225 registros). El contrato mensual presenta 43,06% de abandono, frente a 11,05% en un año y 2,93% en dos años. Estas diferencias son asociaciones de la muestra.



La limpieza y las nueve figuras del EDA están en el notebook 01 y reports/data. Los rangos observados generan advertencias en inferencia; no recortan valores.

El CSV crudo se obtiene desde Kaggle mediante el comando documentado. No se redistribuye en el repositorio; el ejemplo de la web contiene solo seis perfiles ficticios, identificados con DEMO-.

Protocolo experimental y prevención de fuga

Etapa	Regla registrada
Partición	60/20/20 estratificada; semilla 42. Entrenamiento 4.225; validación 1.409; prueba final 1.409.
Transformación	Imputación, codificación y escalado según la familia dentro del pipeline. Sus estadísticas se aprenden solo en cada entrenamiento.
Búsqueda	RandomizedSearchCV: 20 combinaciones, cinco folds estratificados; F1 de la clase positiva.
Calibración	Predicciones fuera de fold de entrenamiento. Sigmoid si mejora Brier y log-loss al menos 1%; SVM utiliza Platt.
Umbral	Rejilla 0,05-0,95 en validación: maximizar F1; empate, cercanía a 0,5 y luego menor umbral.
Selección	F1, ROC-AUC y recall con tolerancia 0,005; estabilidad CV y parsimonia como desempate. No se elige por el mayor F1 aislado.
Prueba final	Una evaluación del ganador congelado el 09/11/2026. No se reutiliza para decidir variables, parámetros, calibración o umbral.

Ingeniería de variables. Se comparó cada familia con y sin seis derivadas: número de servicios; cliente nuevo (antigüedad <=6); contrato mensual; pago automático; internet sin soporte; y cargo mensual dividido por servicios, con denominador mínimo uno. La creación es determinística y forma parte del pipeline.

Las cinco familias son Regresión Logística, Random Forest, XGBoost, LightGBM y SVM. El vencedor conserva los 19 predictores originales.

Comparación y selección del ganador

Resultados de **validación**. Cada fila representa una familia y variante. Los umbrales se fijan en validación; estas cifras no son el resultado final reservado.

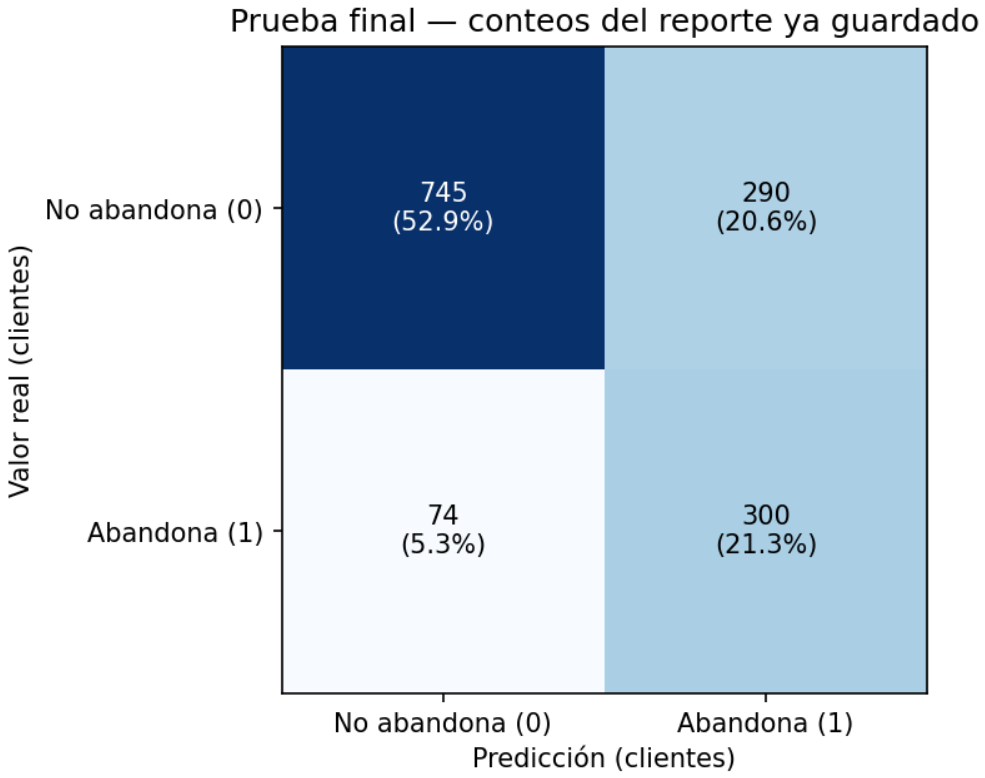
Candidato	Acc.	Prec.	Recall	F1	AUC	Umbral
Random Forest original	0.792	0.585	0.746	0.656	0.858	0.340
Random Forest + derivadas	0.776	0.554	0.797	0.654	0.857	0.300
XGBoost + derivadas	0.784	0.568	0.767	0.653	0.855	0.340
LightGBM + derivadas	0.775	0.553	0.794	0.652	0.858	0.310
XGBoost original	0.766	0.538	0.824	0.651	0.856	0.250
Reg. logística + derivadas	0.764	0.537	0.818	0.648	0.860	0.270
SVM original	0.796	0.598	0.703	0.646	0.841	0.410
Reg. logística original	0.803	0.617	0.676	0.645	0.856	0.420
SVM + derivadas	0.776	0.556	0.765	0.644	0.840	0.310
LightGBM original	0.765	0.540	0.783	0.639	0.847	0.310

Random Forest original alcanza F1 0,656 y XGBoost original F1 0,651. La tolerancia de 0,005 mantiene varios candidatos; el protocolo continúa con AUC, recall, estabilidad y parsimonia. El ganador registrado es XGBoost sin derivadas; su recall de validación es 0,824, AUC 0,856 y umbral 0,25. No es una selección retrospectiva con la prueba final.

Configuración ganadora. 200 árboles, profundidad 6, learning_rate=0,01, subsample=0,7 y scale_pos_weight=2,769. Calibración sigmoid, cinco folds, ensemble=False; ajuste exclusivo sobre entrenamiento.

Evaluación final e implicaciones

Accuracy	Precision	Recall	F1	ROC-AUC
0.742	0.508	0.802	0.622	0.830



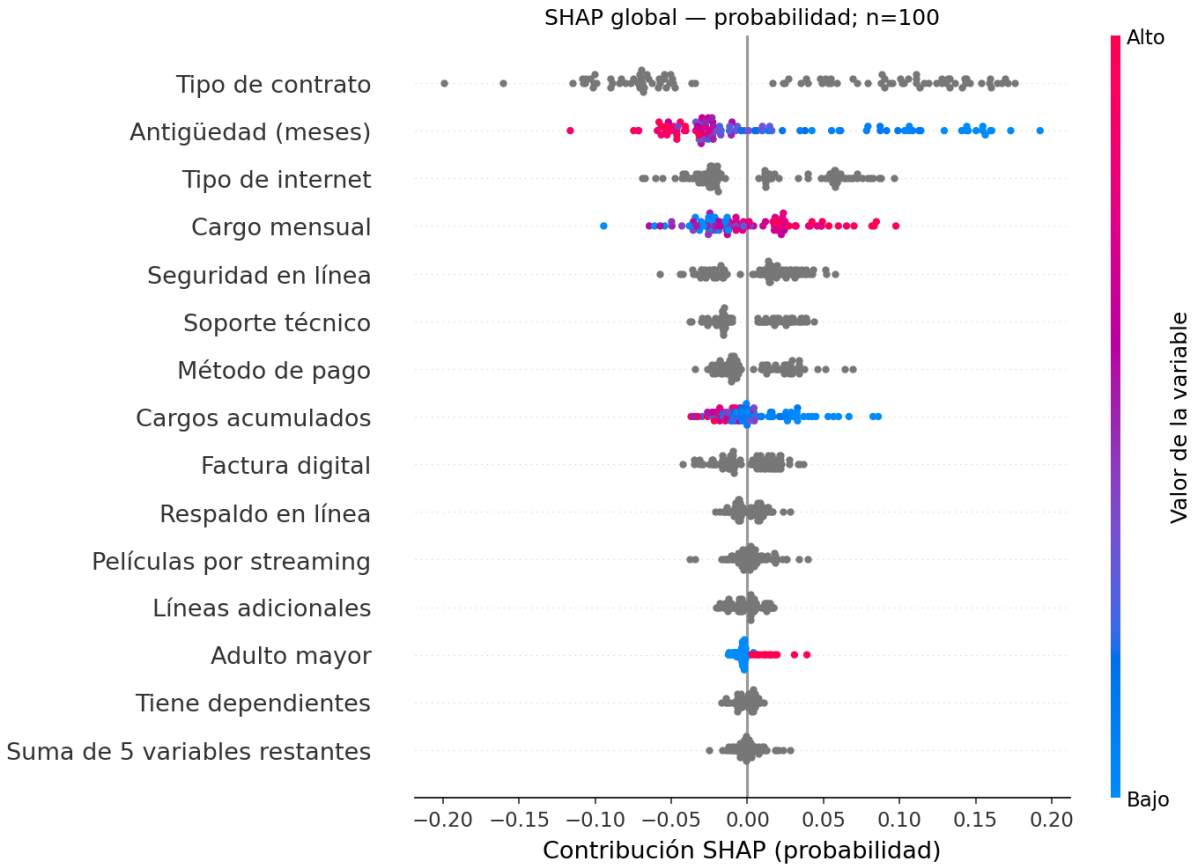
De 374 abandonos, se detectan 300 y se omiten 74. De 1.035 permanencias, 745 se clasifican correctamente y 290 reciben una alerta falsa. Precision 0,508 implica que alrededor de la mitad de las alertas positivas son abandonos observados. Una campaña debe considerar el costo de contactar y de no detectar, sin asumir que todos los clientes señalados abandonarán.

Average Precision 0.623; Brier 0.142; log-loss 0.436. Son resultados guardados del conjunto final; no se recalculan desde la web.

Las curvas ROC y calibración publicadas corresponden a validación. No se fabrica una curva ROC final: no se conservan las probabilidades originales de esa evaluación.

Explicabilidad y sugerencias de retención

Permutation SHAP explica la probabilidad calibrada del estimador completo, con referencia fija de 100 registros de entrenamiento. Las contribuciones se agrupan en los 19 predictores y reconstruyen la probabilidad con tolerancia absoluta 0,000001. El gráfico global usa 100 registros de entrenamiento.



En cada predicción se muestran los cinco factores de mayor contribución absoluta; la vista individual permite consultar los 19. El signo indica aumento o reducción respecto a la referencia, en puntos de probabilidad.

Las sugerencias son reglas determinísticas apoyadas por factores positivos y contexto del cliente: revisar contrato, facturación, soporte o servicios. La prioridad es probabilidad × cargo mensual. Las bandas 0,35 y 0,65 son convenciones operativas, diferentes del umbral binario 0,25. Género y edad no se usan para asignar beneficios; el predictor aún requiere una auditoría de equidad.

Aplicación, arquitectura y seguridad

Sección	Flujo implementado
Resumen	Contexto del dataset, abandono por contrato, comparación de candidatos y matriz final guardada.
Predicción	19 variables, coherencia de servicios, probabilidad, decisión binaria, banda de riesgo, SHAP y exportación. Se invalida al editar.
Cartera CSV	Carga UTF-8/coma, validación completa, cálculo por cliente, filtros, búsqueda, selección de fila y exportación.
Explicabilidad	Gráfico global y contribuciones individuales del cliente seleccionado, con base y reconstrucción numérica.
Retención	Lista ordenada por exposición, sugerencias y exportación. Si existe Churn se incluyen solo activos Churn=No.

Separación. app.py inicia ui/app.py; ui/pages.py presenta los flujos con controles nativos. src/application.py verifica recursos y prepara exportaciones; src/schema, inference, explain y recommendations concentran las reglas. El modelo se comparte como recurso público; los datos del usuario y resultados permanecen en su sesión, sin caché global de carteras.

Seguridad. Se comprueba SHA-256 antes de deserializar el Joblib propio y se rechazan dependencias incompatibles. No se permite cargar modelos arbitrarios. Un CSV inválido elimina resultados de la fuente anterior; las selecciones conservan índices técnicos aunque se repitan IDs. Se neutralizan fórmulas en celdas de texto exportadas. No hay credenciales ni datos personales en los ejemplos.

Capacidad medida. Límite web: 100 registros y 10 MB. Un lote local de 100 perfiles ficticios con probabilidad, SHAP y recomendaciones tardó 34,93 segundos en Windows/Python 3.11.16. No es una cifra de Streamlit Cloud ni una garantía de latencia; el tiempo depende del servidor y los datos.

La aplicación en funcionamiento

Capturas de la aplicación Streamlit implementada y verificada en navegador. La primera muestra el resumen científico; la segunda, una predicción real del modelo congelado sobre un perfil ficticio. No son pantallas simuladas.



Resumen publicado en Streamlit Community Cloud: acceso público verificado.



Ejemplo ficticio DEMO-INDIVIDUAL: probabilidad estimada 72,2%, riesgo alto y decisión de abandono al umbral 25%. No es una predicción sobre una persona real ni una medición de desempeño del modelo.

Verificación, reproducción y demostración

Verificación integrada. 103 pruebas pasan, incluidas entrada inválida, huella corrupta antes de deserializar, CSV seguro, IDs repetidos, predicción real, invalidación al editar, coherencia de servicios, navegación, SHAP, exclusión de abandonos y borrado de sesión. Ruff y formato se comprueban con los comandos del README. Son pruebas técnicas, no estimaciones adicionales de desempeño predictivo.

Para ejecutar. Clonar el repositorio, crear Python 3.11 e instalar requirements-dev-lock.txt para desarrollo o requirements.txt para servir la web. Ejecutar python -m streamlit run app.py. El dataset crudo no es necesario para usar la aplicación con el modelo y reportes publicados.

Publicación verificada. La web abre sin iniciar sesión. Se comprobaron predicción, carga del CSV ficticio de seis filas, scoring, descarga, SHAP global e individual, cambio de cliente y retención de cinco activos. También se verificaron aislamiento entre sesiones y borrado de resultados. La descarga coincide numéricamente con Windows: diferencia máxima de probabilidad 5,56e-17 y de valores SHAP 1,60e-10, dentro de la tolerancia SHAP existente de 1e-6. Se conservan las mismas recomendaciones. La comparación usa perfiles ficticios, sin reevaluar la prueba final.

Demostración sugerida (5-7 minutos).
1. Resumen: explicar el problema, las particiones y la diferencia entre validación y prueba final.
2. Predicción: calcular el perfil ficticio inicial y explicar SHAP, umbral binario y bandas; editar un dato para mostrar la invalidación.
3. Cartera CSV: probar los seis perfiles ficticios y analizar; filtrar y exportar. El CSV de ejemplo se descarga desde la misma pantalla.
4. Explicabilidad: mostrar global y cliente, verificar referencia más contribuciones y aclarar que no es causalidad.
5. Retención: verificar orden por exposición y que DEMO-006, con Churn=Yes, queda fuera; explicar límites de las sugerencias.
6. Borrar la sesión y presentar los entregables del README.

Trazabilidad. La reproducción del 10/11 coincide con los diez candidatos y el ganador usando solo entrenamiento/validación. No sustituye el experimento original: los archivos históricos detallados referidos por sus huellas no están disponibles y se conserva esa limitación.

La reproducción científica exige Python 3.11.16 y versiones exactas. La web comprueba Python 3.11 (permite parches) y las siete bibliotecas del manifiesto exactamente. Las huellas y .gitattributes conservan los bytes del modelo y los reportes entre sistemas.

Limitaciones, conclusiones y fuentes

El dataset es una muestra histórica sin secuencia temporal suficiente para prometer riesgo en 30/60/90 días. La validez fuera de la población Telco, estabilidad temporal y equidad por subgrupos necesitan evaluación adicional. La web advierte valores fuera de rangos de entrenamiento, pero no verifica que un nuevo negocio tenga la misma distribución.

La exposición mensual no es ingreso perdido ni ingreso recuperable demostrado; no se atribuye moneda al dataset. Las recomendaciones son hipótesis comerciales, no acciones ejecutadas. Harían falta revisión operativa y experimentos controlados para estimar su efectividad.

El ganador ofrece un compromiso favorable a detección de abandonos, con costo de falsas alertas explícito. Chuard conserva un protocolo reproducible y separa evidencia científica de sugerencias de operación. La aplicación presenta las estimaciones con sus factores y límites.

Fuentes y evidencia.

Telco Customer Churn · Kaggle

Código, notebooks, manifiestos y resultados · Chuard

Validación cruzada y pipelines · scikit-learn

PermutationExplainer · SHAP

Despliegue y dependencias · Streamlit

Huella del modelo congelado (SHA-256):

0bb0a8542c14f3e23e2fd779fc8b3dd2
c488c6c28db069411d23e84b28d1cea1